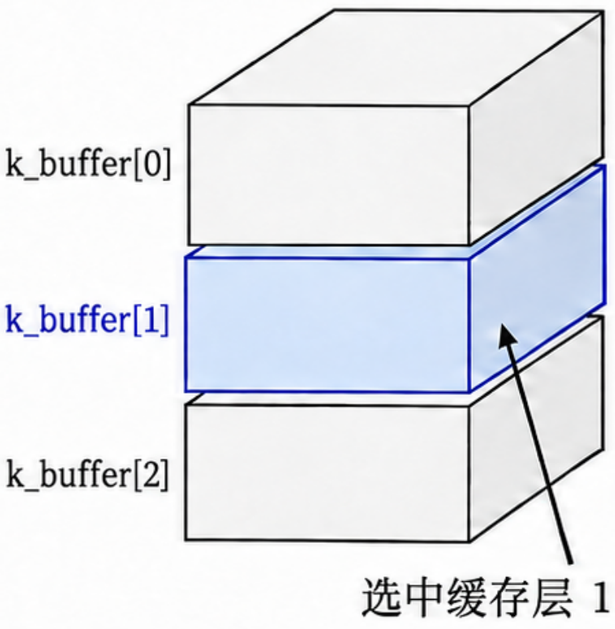
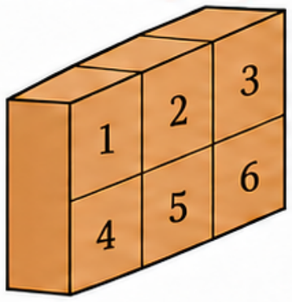
本例分配相邻槽位：indices = [3, 4]； 写入第 1 个缓存层。

k_buffer：按缓存层组织

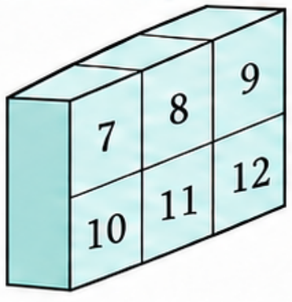


写入前：两个 token 的 K

token A · k[0:1]



token B · k[1:2]

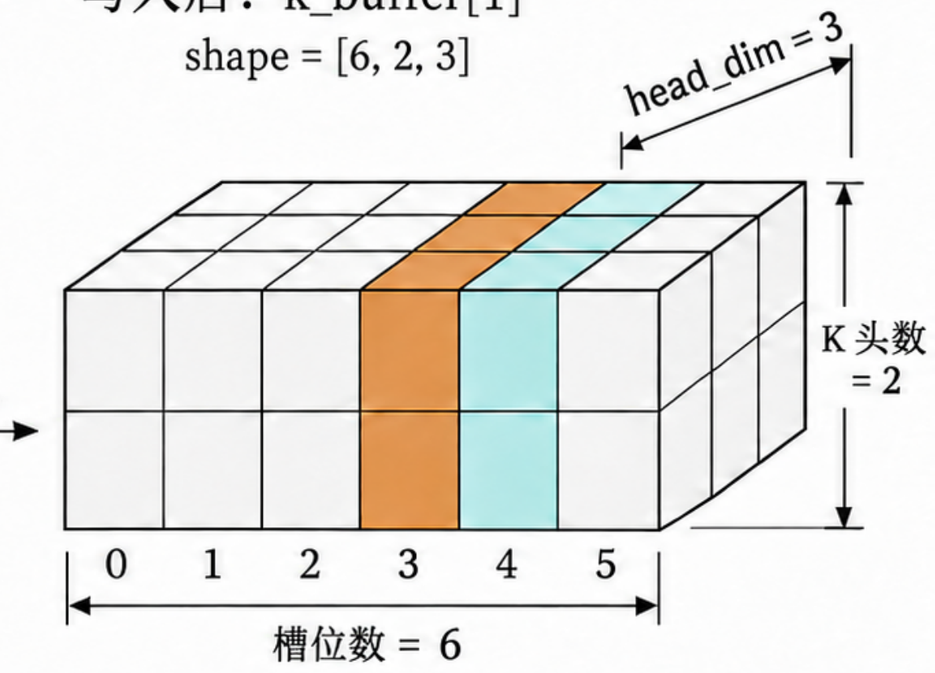


每块 shape = [1, 2, 3]

按编号写入

写入后：k_buffer[1]

shape = [6, 2, 3]



k_buffer[1][3] ← k[0]
k_buffer[1][4] ← k[1]

每个槽位容纳一个 token 的完整 K 数据：[2 个 head，每头 3 个元素]。
楼层是逻辑分层示意；实际是列表中的三维 Tensor，数据位于 GPU 显存。